

Detectando casos de COVID a partir de imagens de Tomografia

Eric Sticchi Zambom

Juliana Félix

Resumo

O SARS-CoV-2 é um novo coronavírus, responsável pela atual pandemia de COVID-19, o qual já infectou e causou a morte de milhares de pessoas em todo o mundo. Neste artigo exploramos um método de CNN (Convolutional Neural Network), onde analisamos as tomografias computadorizadas de pacientes reais em hospitais do estado de São Paulo para a identificação de infectados pelo SARS-CoV-2.

COVID-19

De acordo Nogueira (2020) o coronavírus SARS-CoV-2 é o agente etiológico da COVID-19, uma doença altamente infecciosa que afeta principalmente o trato respiratório inferior, cujos primeiros casos foram relatados na China em 2019. Desde então, o vírus se espalhou por todo o mundo, causando uma pandemia que resulta em consequências catastróficas para a saúde e a economia globais, além dos milhões de mortes e sequelas permanentes em muitos sobreviventes, especialmente em países em desenvolvimento como o Brasil.





Figura 1 - Estrutura Sars-CoV-2
Fonte: Adaptado de LAMERS, Mart M (2022)

Dados Utilizados

De acordo com Soares...(2020) este conjunto de dados (dataset) de tomografia computadorizada (TC) de acesso público para SARS-CoV-2, contém 1252 exames de TC positivos para infecção por SARS-CoV-2 (COVID-19) e 1230 exames de TC de pacientes não infectados por SARS-CoV-2, totalizando 2482 exames de TC. Esses dados foram coletados de pacientes reais em hospitais de São Paulo, Brasil.



*Figura 2 - Amostra das Imagens do Dataset
Fonte: Soares...(2020)*

Pré-Processamento de Imagens

Segundo WANG, Jason...(2017) as transformações tradicionais consistem em usar uma combinação de transformações afins para manipular os dados de treinamento. Portanto, para cada imagem de entrada, geramos outras imagens “duplicadas” que são deslocadas, ampliadas/reduzidas, rotacionadas ou invertidas,. Tanto a imagem quanto suas duplicatas são inseridas na rede neural. Para um conjunto de dados de tamanho N, geramos um conjunto de dados de tamanho 10N.




Figura 3 - Imagens com transformações simples
Fonte: Soares...(2020)

CNN (Convolutional Neural Network)

Em concordância com LEE, Hagyeong...(2019) utilizamos uma separação de treinamento para o modelo de 0.2 (20%) para validação e 0.8 (80%) para o treinamento.

Dada a natureza simples de um classificador de imagens com apenas 2 parâmetros, as limitações propostas pelo ambiente de execução (Google Colab) e a falta de orçamento para a utilização de uma GPU (Graphics Processing Unit) dedicada, montamos uma rede neural estruturada da seguinte maneira:

Model: "sequential_5"

Layer (type)	Output Shape	Param #
sequential_4 (Sequential)	(None, 250, 250, 3)	0
rescaling_5 (Rescaling)	(None, 250, 250, 3)	0
conv2d_9 (Conv2D)	(None, 250, 250, 16)	448
max_pooling2d_9 (MaxPooling2D)	(None, 125, 125, 16)	0
conv2d_10 (Conv2D)	(None, 125, 125, 32)	4,640
max_pooling2d_10 (MaxPooling2D)	(None, 62, 62, 32)	0
conv2d_11 (Conv2D)	(None, 62, 62, 64)	18,496
max_pooling2d_11 (MaxPooling2D)	(None, 31, 31, 64)	0
dropout_1 (Dropout)	(None, 31, 31, 64)	0
flatten_3 (Flatten)	(None, 61504)	0
dense_6 (Dense)	(None, 128)	7,872,640
dense_7 (Dense)	(None, 2)	258

Total params: 7,896,482 (30.12 MB)

Trainable params: 7,896,482 (30.12 MB)

Non-trainable params: 0 (0.00 B)

Figura 4 - Estrutura da CNN
Fonte própria

O modelo foi treinado por 50 épocas, com as imagens fixadas em um tamanho de 250 x 250 pixels.




Figura 5 - Treinamento da CNN
Fonte: Própria

Resultados

Após a fase de pré-processamento dos dados, com o aumento da base de dados através de transformações simples, o modelo apresentou uma melhora considerável.




Figura 6 - Modelo de CNN sem pré-processamento
Fonte: Própria




Figura 7 - Modelo CNN depois do pré-processamento de imagens
Fonte: Própria

Dadas as limitações técnicas previstas o modelo teve de ser limitado a 50 épocas e o dataset utilizado não puderam ser expandidos para uma escala de consideração comercial. No entanto os resultados obtidos indicam que o modelo de classificação de imagens apresentou um desempenho satisfatório. A acurácia de 0,9117 no conjunto de treinamento e de 0,9173 no conjunto de validação, aliadas aos baixos valores de *loss*, sugerem uma boa capacidade de generalização, sem indícios significativos de sobreajuste. Do ponto de vista acadêmico, esses resultados demonstram que a arquitetura e os hiperparâmetros adotados foram adequados para o problema proposto. Ainda assim, estudos futuros podem explorar ajustes adicionais no modelo ou técnicas de regularização e aumento de dados, visando aprimorar ainda mais o desempenho e a robustez da classificação.

Referências

- KIM, Changhyun; LEE, Sangjin. CONAN: Markov Image-Based Preprocessing for Robust Screenshot Detection Using Deep Learning. *Digital Object Identifier* 10.1109/ACCESS.2025.3630498, recebido em 9 de outubro de 2025, aceito em 3 de novembro de 2025.
- LEE, Hagyeong; SONG, Jongwoo. Introduction to convolutional neural network using Keras; an understanding from a statistician. *Communications for Statistical Applications and Methods*, 2019, Vol. 26, No. 6, p. 591–610. DOI: 10.29220/CSAM.2019.26.6.591.
- MUMUNI, Alhassan; MUMUNI, Fuseini. CNN Architectures for Geometric Transformation-Invariant Feature Representation in Computer Vision: A Review. *SN Computer Science*, 2021, 2(340). DOI: 10.1007/s42979-021-00735-0.
- WANG, Jason; PEREZ, Luis. The Effectiveness of Data Augmentation in Image Classification using Deep Learning. Stanford University, 2017.
- MIKOŁAJCZYK, Agnieszka; GROCHOWSKI, Michał. Data augmentation for improving deep learning in image classification problem. *Department of Control Systems Engineering, Faculty of Electrical and Control Engineering, Gdańsk University of Technology*.
- NOGUEIRA, José Vagner Delmiro. CONHECENDO A ORIGEM DO SARS-COV-2 (COVID 19). **Revista Saúde e Meio Ambiente**, v. 11, n. 2, p. 115-124, 2020.
- Soares, Eduardo, Angelov, Plamen, Biaso, Sarah, Higa Froes, Michele, and Kanda Abe, Daniel. "SARS-CoV-2 CT-scan dataset: A large dataset of real patients CT scans for SARS-CoV-2 identification." medRxiv (2020). doi: <https://doi.org/10.1101/2020.04.24.20078584>.
- Angelov, P., & Soares, E. (2020). Towards explainable deep neural networks (xDNN). *Neural Networks*, 130, 185-194.
- LAMERS, Mart M.; HAAGMANS, Bart L. SARS-CoV-2 pathogenesis. **Nature reviews microbiology**, v. 20, n. 5, p. 270-284, 2022.