


Detectando casos de COVID a partir de imagens de Tomografia

Seminário - Machine Learning



The background features a stylized, sketch-like illustration of medical professionals. In the foreground, three individuals are shown from the chest up, wearing white lab coats and face masks. Behind them, another person is visible, also in medical attire. The style is loose and artistic, with visible brushstrokes. The background is a mix of light gray and white geometric shapes, including a large triangle in the upper left and some diagonal lines.

CONTEXTO

- A COVID-19 impactou sistemas de saúde no mundo todo
- Diagnóstico por tomografia é rápido, mas depende de especialistas
- IA pode apoiar decisões médicas
- Deep Learning tem alto desempenho em imagens médicas

**AUTOMATIZAR O DIAGNÓSTICO PODE SALVAR
TEMPO E VIDAS**



OBJETIVO

- Desenvolver uma solução baseada em Deep Learning
- Classificar imagens de tomografia em:
 - COVID
 - Não-COVID



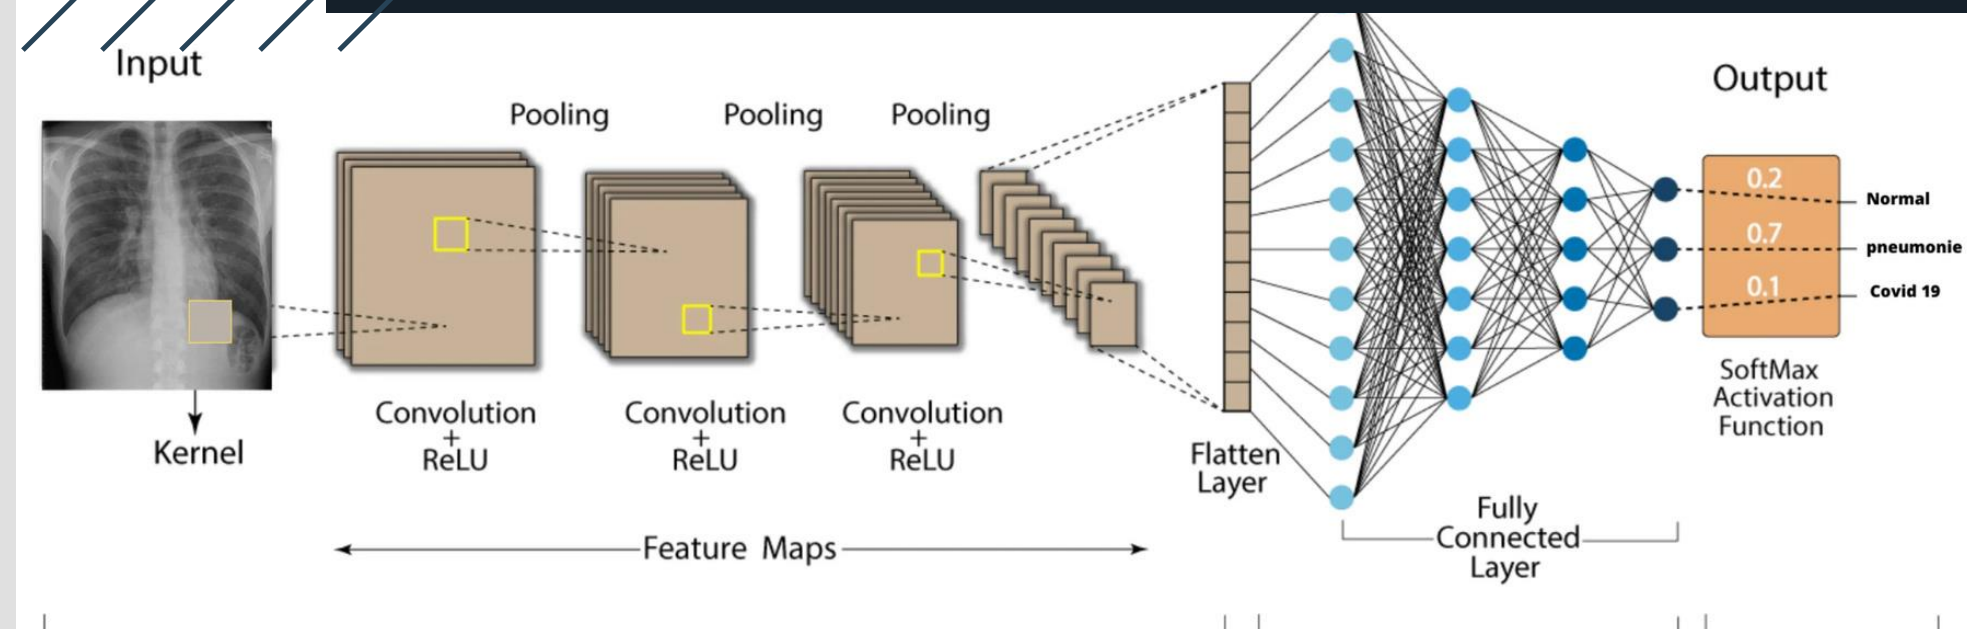
PROBLEMA A SER RESOLVIDO

- Entrada:
 - imagens de tomografia computadorizada
- Saída:
 - classe (COVID / Normal)
- Tipo de problema:
 - Classificação supervisionada
- Desafios:
 - Alta variabilidade das imagens
 - Overfitting
 - Escolha de arquitetura





FUNDAMENTAÇÃO TEÓRICA: DEEP LEARNING

- Redes Neurais Convolucionais (CNNs)
- Uso de convoluções para extração automática de características
- Amplamente utilizadas em:
 - Diagnóstico médico
 - Visão computacional



DATASET

- SARS-CoV-2 CT-Scan Dataset (Kaggle)
- Imagens reais de hospitais do estado de São Paulo
- Classes:
 - COVID
 - Não-COVID
- Dataset público e validado




PRÉ-PROCESSAMENTO DOS DADOS

- Redimensionamento das imagens (250×250)
- Normalização dos pixels
- Divisão:
 - 80% treino
 - 20% validação
- Visualização das amostras





PIPELINE DA SOLUÇÃO (FLUXOGRAMA)





ARQUITETURA DO MODELO

- Camadas convolucionais (16, 32, 64 filtros)
 - MaxPooling
 - Dropout para evitar overfitting
 - Camadas densas finais
 - Função de ativação ReLU
- 



IMPLEMENTAÇÃO

- COLAB em Python
- TensorFlow e Keras
- Execução em ambiente local / Colab
- Código disponível no GitHub


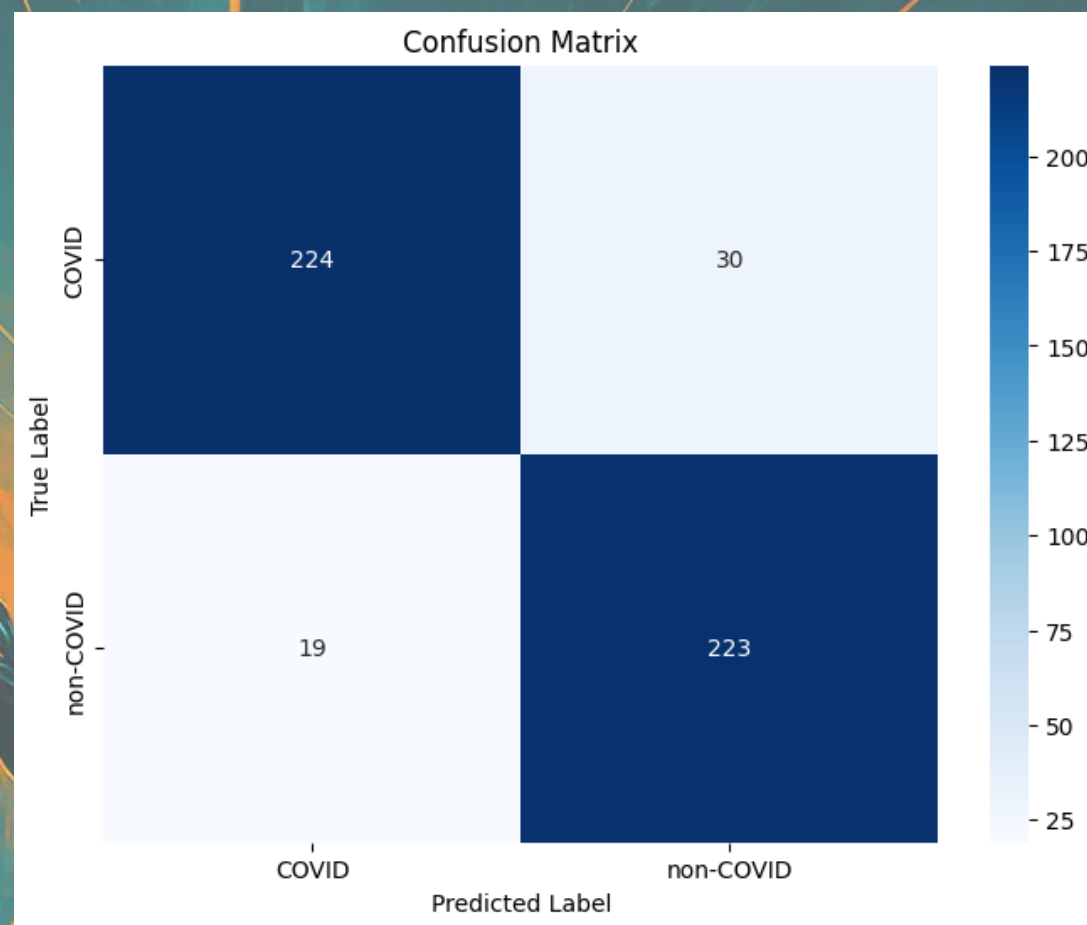
DESAFIOS

- Overfitting inicial
- Escolha manual de hiperparâmetros
- Alto custo computacional
- Tempo de treinamento
- Dataset limitado



RESULTADOS

- Acurácia de 92% nos conjuntos de treinamento e validação
- Baixos valores de perda
- Sem indícios de overfitting




TENDÊNCIAS

- Uso de AutoML completo em saúde
- NAS para modelos médicos
- Modelos explicáveis (XAI)
- Aprendizado federado
- Integração com sistemas hospitalares



MELHORIAS

- Aumentar a base de dados;
- Utilizar uma máquina dedicada para um treinamento mais extenso;
- Ensembles de CNNs;
- Supervisão humana;



A futuristic racing track with a blue and orange color scheme. The track is illuminated with glowing lines, and a large 'FINISH' sign is visible in the distance. The scene is set in a tunnel-like environment with a high-tech, digital aesthetic.

CONCLUSÃO

- Deep Learning mostrou-se eficaz
- Reduz esforço humano
- Agiliza e automatiza o processo
- Solução com impacto real

**AUTOML É O CAMINHO PARA SOLUÇÕES
INTELIGENTES, ESCALÁVEIS E ACESSÍVEIS**



Obrigado