


# Detectando casos de COVID a partir de imagens de Tomografia

Seminário - Machine Learning





# CONTEXTO

- A COVID-19 impactou sistemas de saúde no mundo todo
- Diagnóstico por tomografia é rápido, mas depende de especialistas
- IA pode apoiar decisões médicas
- Deep Learning tem alto desempenho em imagens médicas

**AUTOMATIZAR O DIAGNÓSTICO PODE SALVAR  
TEMPO E VIDAS**

# OBJETIVO



- Desenvolver uma solução baseada em Deep Learning
- Classificar imagens de tomografia em:
  - COVID
  - Não-COVID





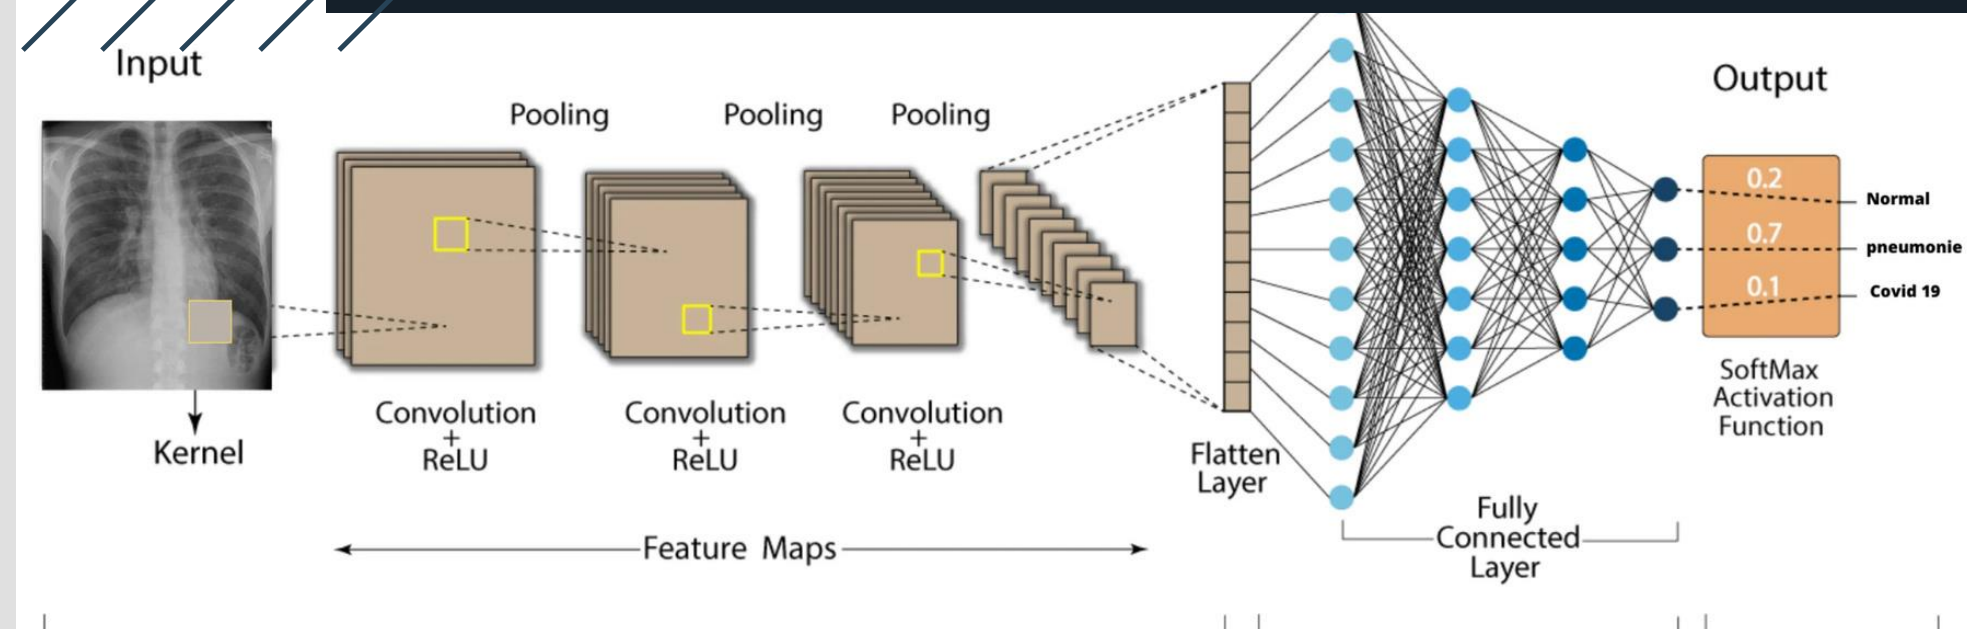
# PROBLEMA A SER RESOLVIDO

- Entrada:
  - imagens de tomografia computadorizada
- Saída:
  - classe (COVID / Normal)
- Tipo de problema:
  - Classificação supervisionada
- Desafios:
  - Alta variabilidade das imagens
  - Overfitting
  - Escolha de arquitetura





# FUNDAMENTAÇÃO TEÓRICA: DEEP LEARNING

- Redes Neurais Convolucionais (CNNs)
- Uso de convoluções para extração automática de características
- Amplamente utilizadas em:
  - Diagnóstico médico
  - Visão computacional



# DATASET

- SARS-CoV-2 CT-Scan Dataset (Kaggle)
- Imagens reais de hospitais do estado de São Paulo
- Classes:
  - COVID
  - Não-COVID
- Dataset público e validado




# PRÉ-PROCESSAMENTO DOS DADOS

- Redimensionamento das imagens (250×250)
- Normalização dos pixels
- Divisão:
  - 80% treino
  - 20% validação
- Visualização das amostras






# PIPELINE DA SOLUÇÃO (FLUXOGRAMA)








# ARQUITETURA DO MODELO

- Camadas convolucionais (16, 32, 64 filtros)
  - MaxPooling
  - Dropout para evitar overfitting
  - Camadas densas finais
  - Função de ativação ReLU
- 



# IMPLEMENTAÇÃO

- COLAB em Python
- TensorFlow e Keras
- Execução em ambiente local / Colab
- Código disponível no GitHub




# DESAFIOS

- Overfitting inicial
- Escolha manual de hiperparâmetros
- Alto custo computacional
- Tempo de treinamento
- Dataset limitado







# RESULTADOS

- Acurácia de 92% nos conjuntos de treinamento e validação
- Baixos valores de perda
- Sem indícios de overfitting



# TENDÊNCIAS


- Uso de AutoML completo em saúde
- NAS para modelos médicos
- Modelos explicáveis (XAI)
- Aprendizado federado
- Integração com sistemas hospitalares





# MELHORIAS

- Aumentar a base de dados;
- Utilizar uma máquina dedicada para um treinamento mais extenso;
- Ensembles de CNNs;
- Supervisão humana;








# CONCLUSÃO

- Deep Learning mostrou-se eficaz
- Reduz esforço humano
- Agiliza e automatiza o processo
- Solução com impacto real

**AUTOML É O CAMINHO PARA SOLUÇÕES  
INTELIGENTES, ESCALÁVEIS E ACESSÍVEIS**





Obrigado